

Arquitetura de Datacenters e Modelos de Operação

Infraestruturas de Computação na Nuvem, Aula 02

Catarina Silva

ESTGA, Universidade de Aveiro | 2026

Agenda (1/2)

- Classificação Uptime Institute: os quatro Tiers.
- Topologias de rede em datacenter.
- Tráfego este-oeste vs norte-sul.
- Cálculo de disponibilidade e "noves" de disponibilidade.
- SLAs: o que contêm na prática.
- Normas de classificação: Uptime, TIA-942 e EN 50600.

Agenda (2/2)

- Modelos de operação: on-premises, colocation, cloud pública.
- CapEx vs OpEx.
- Regiões e zonas de disponibilidade.
- Tendências: modulares, edge e sustentabilidade.
- Caso de estudo: o servidor desta UC.

Classificação Uptime Institute (1/2)

- O Uptime Institute define quatro níveis (Tiers) de maturidade de infraestrutura, de I a IV.
- Tier I: infraestrutura básica, sem redundância; suscetível a interrupções por manutenção ou falha.
- Tier II: introduz componentes redundantes ($N+1$), mas mantém uma única via de distribuição.

Classificação Uptime Institute (2/2)

- Tier III: múltiplas vias de distribuição independentes, permitindo manutenção sem interrupção do serviço.
- Tier IV: tolerância a falhas, com redundância $2N$ em todos os componentes críticos.
- Níveis de redundância: **N** (capacidade mínima necessária), **$N+1$** (uma unidade extra), **$2N$** (duplicação completa do sistema).

Topologias de Rede em Datacenter (1/2)

- **Three-tier:** organização clássica em três camadas — core, aggregation e access.
- A camada core interliga o datacenter ao exterior; a aggregation concentra tráfego; a access liga diretamente os servidores.
- Limitação: o tráfego entre servidores em racks diferentes percorre várias camadas, introduzindo latência.

Topologias de Rede em Datacenter (2/2)

- **Leaf-spine** (topologia Clos): cada switch leaf liga-se a todos os switches spine, sem ligações diretas entre leafs.
- Garante um número previsível e constante de saltos entre quaisquer dois servidores.
- Mais adequada a tráfego este-oeste intenso, típico de aplicações distribuídas e cloud.

Tráfego Este-Oeste vs Norte-Sul

- **Tráfego norte-sul:** entra ou sai do datacenter, entre clientes externos e os servidores internos.
- **Tráfego este-oeste:** circula entre servidores dentro do próprio datacenter (ex. um serviço a chamar outro).
- Aplicações distribuídas e arquiteturas de microsserviços multiplicaram o volume de tráfego este-oeste.
- A topologia leaf-spine foi desenhada precisamente para este cenário: qualquer par de servidores fica a igual distância (dois saltos).

Cálculo de Disponibilidade (1/2)

- Disponibilidade (SLA) expressa habitualmente em percentagem de tempo operacional: os chamados "noves".
- 99,9% (três noves) corresponde a cerca de 8,76h de downtime por ano.
- 99,99% (quatro noves) corresponde a cerca de 52,6 minutos de downtime por ano.
- 99,999% (cinco noves) corresponde a cerca de 5,26 minutos de downtime por ano.

Cálculo de Disponibilidade (2/2)

- Componentes em **série**: a disponibilidade combinada é o produto das disponibilidades individuais, $A = A_1 \times A_2 \times \dots \times A_n$.
- Componentes em série reduzem sempre a disponibilidade total do sistema.
- Componentes em **paralelo** (redundantes): $A = 1 - (1 - A_1)(1 - A_2) \dots (1 - A_n)$.
- A redundância em paralelo é a estratégia central para atingir Tiers mais elevados.

SLAs na Prática

- Um **SLA** (Service Level Agreement) é um contrato formal entre fornecedor e cliente sobre o nível de serviço prestado.
- Tipicamente inclui: percentagem de disponibilidade garantida, janelas de manutenção previstas, e tempo máximo de resposta a incidentes.
- Pode incluir também **MTTR** (Mean Time To Repair) alvo e penalizações – normalmente créditos de serviço – se o compromisso não for cumprido.
- O Tier do datacenter é um dos fatores que determina que nível de SLA é realisticamente possível oferecer.

Outras Normas de Classificação

- A classificação do Uptime Institute é a mais citada, mas não é a única.
- **TIA-942**: norma norte-americana de infraestrutura de telecomunicações para datacenters, que define níveis *Rated-1* a *Rated-4*.
- Cobre também aspetos que os Tiers não abordam em detalhe, como cablagem estruturada e disposição do espaço.
- **EN 50600**: série de normas europeias sobre instalações e infraestruturas de datacenters, com classes de disponibilidade de 1 a 4.
- Abrange igualmente eficiência energética e segurança física, numa abordagem mais ampla.
- Os níveis das diferentes normas são comparáveis em espírito, mas não diretamente

Modelos de Operação

- **On-premises:** datacenter próprio, com controlo total sobre a infraestrutura, mas maior investimento inicial e operacional.
- **Colocation:** a organização aluga espaço, energia e refrigeração num datacenter de terceiros, mantendo o controlo sobre o equipamento.
- **Cloud pública:** recursos fornecidos por um terceiro, com faturação por utilização e sem gestão física da infraestrutura.

CapEx vs OpEx

- **CapEx** (despesa de capital): investimento inicial em equipamento e instalações, amortizado ao longo de vários anos.
- Modelo típico do on-premises: é preciso comprar capacidade para o pico previsto, que fica subutilizada a maior parte do tempo.
- **OpEx** (despesa operacional): custo recorrente, proporcional ao consumo – o modelo da cloud pública.
- Vantagem do OpEx: alinha o custo com a procura real e evita imobilizar capital.
- Contrapartida: em cargas estáveis e previsíveis a longo prazo, o custo total da cloud pode superar o de infraestrutura própria.
- A decisão é económica além de técnica, e depende sobretudo da variabilidade da

Regiões e Zonas de Disponibilidade

- Os fornecedores de cloud organizam a infraestrutura em **regiões**: áreas geográficas distintas, com datacenters próprios.
- Cada região divide-se em **zonas de disponibilidade**: datacenters fisicamente separados, com energia e rede independentes, mas ligados por rede de baixa latência.
- Distribuir réplicas por várias zonas protege contra a falha de um datacenter inteiro – e não apenas de um servidor.
- Distribuir por várias regiões protege contra falhas de maior escala e aproxima o serviço dos utilizadores.
- A escolha da região é também condicionada por requisitos legais de localização dos dados (ex. RGPD).

Tendências

- Datacenters modulares/contentorizados: unidades pré-fabricadas, de implantação rápida e capacidade escalável.
- Datacenters de edge: infraestrutura de menor dimensão, próxima dos utilizadores finais, reduzindo latência.
- Ambas as tendências respondem à procura crescente por proximidade geográfica e rapidez de implantação.

Sustentabilidade e Métricas Ambientais

- O consumo energético dos datacenters tornou-se uma preocupação central, económica e ambiental.
- Além do **PUE** (Aula 01), o mesmo consórcio (The Green Grid) definiu métricas complementares.
- **WUE** (Water Usage Effectiveness): água consumida por unidade de energia do equipamento de TI – relevante em arrefecimento evaporativo.
- **CUE** (Carbon Usage Effectiveness): emissões de carbono por unidade de energia consumida pelo equipamento de TI.
- Estratégias comuns: localizar datacenters em climas frios, reaproveitar calor residual e contratar energia de fontes renováveis.

Caso de Estudo: o Servidor Central desta UC

- O servidor Proxmox VE usado nos laboratórios desta UC é, do ponto de vista do datacenter, um único servidor físico.
- Questão de reflexão: que Tier lhe atribuiria, tendo apenas um servidor sem fonte de alimentação ou via de rede redundante?
- Todas as VMs de todos os alunos correm sobre o mesmo hardware – um exemplo direto de *resource pooling* (Aula 01) e também de single point of failure (Aula 09).
- Vamos observar dados reais deste servidor no Guião 02.

Síntese da Aula (1/2)

- Os Tiers do Uptime Institute classificam datacenters segundo o nível de redundância (N , $N+1$, $2N$).
- A topologia leaf-spine substitui progressivamente a three-tier em ambientes cloud, pela previsibilidade de latência.
- A disponibilidade combinada depende de componentes estarem em série (reduz) ou paralelo (aumenta).

Síntese da Aula (2/2)

- Cada "nove" adicional de disponibilidade reduz drasticamente o downtime anual tolerável; um SLA formaliza esse compromisso, com MTTR e penalizações associadas.
- Existem três grandes modelos de operação: on-premises, colocation e cloud pública, com diferentes compromissos entre controle e custo.
- Datacenters modulares e de edge respondem a necessidades de escala e latência cada vez mais exigentes; o nosso próprio servidor de laboratório é um pequeno caso de estudo destes conceitos.

Obrigada.

Questões e comentários